33-脑裂: 一次奇怪的数据丢失

你好,我是菲德钧。

在使用主从集群时,我曾遇到过这样一个问题:我们的主从集群有1个主库、5个从库和3个哨兵实例,在使用的讨理中,野们发现室户做发送的一些数据丢失了。这直接影响到了业务层的数据可靠性。

通过一系列的问题排查,我们才知道,这其实是主从集群中的脑裂问题导致的

所謂的驗製,就是指在主从集群中,同时有两个主节点,它们都能搜收写话家。而與殺國直接的影响,就是 客戶端不知道应该往鄉-生节点写入数据。结果就是不同的客户做《往不同的主节点上写入数据。而且,严 審的话。縣尚本洲—每每等数据表示。

那么,主从集群中为什么会发生脑裂?脑裂为什么又会导致就更安呢?我们这如何避免脑裂的发生呢?这 节课,我就结合我遇见的这个真实问题,你你一起分析和定位问题,帮助你掌握脑裂的成员。后果和应对方 法。

为什么会发生脑裂?

别才我提到,我最初发现的问题是,在主从集群中,客户端发送的数据丢失了。所以,我们首先要弄明白, 为什么数据会丢失?是不是数载简罗出了问题?

第一步:确认是不是数据同步出现了问题

在主从集群中发生数据丢失,最常见的原因就是主席的数据还没有同步到从库,结果主席发生了故障,等从 度升级为主度后,未同步的数据就丢失了。

如下图所示,新写入主库的数据a:1、b:3,就因为在主库故障前未同步到从库而丢失了。



如果是这种情况的数据丢失,我们可以通过比对主从席上的复制进度差值来进行判断,也就是计算 master_repl_offset和slave_repl_offset的差值。如果从席上的slave_repl_offset/小于原主库的 master_repl_offset, 那么,我们就可以认定数据丢失是由数据同步未完成导致的。

我们在部署主从集群时,也监测了主席上的master_repl_offset,以及从库上的slave_repl_offset,但是, 当我打双股股票买后,我打拾宣了新主席升级前的slave_repl_offset,以及原主席的 master_repl_offset,它们是一致的,也就看说,这个升级为新主席的从库,在升级时已经和原主库的数据 保持一致了。那么,为什么还会出现客户端发放的数据丢失呢?

分析到这里,我们的第一个设想就被推翻了。这时,我们想到,所有的数据操作都是从客户端发送给Redis 实例的,那么,是不是可以从客户端操作日志中发现问题呢?紧接着,我们就把目光转到了客户端。

第二步:排查客户端的操作日志,发现脑裂现象

在排查客户端的操作用当时,聚们发现,在主从切换后的一段时间内,有一个客户端仍然在和原主部通信, 并没有和升级的新主席进行交互。这就相当于主从集审中同时有了两个主席。根据这个进象,我们就想到了 在分布式主从集群发生故障时边板的一个问题:脑膜。

但是,不同客户端给两个主库发送数据写操作,按道理来说,只会导致新数据会分布在不同的主库上,并不 会造成数据丢失。那么、为什么我们的数据仍然丢失了呢?

到这里,我们的掉查想路又一次中新了。不过,在分析问题时,我们一直认为"从原理出发是追本渊源的好 方法"。 脑裂是发生在主从切换的过程中,我们猜测,肯定是漏掉了主从集群切换过程中的某个环节,所 以,我们得那可的做自命询了主从切缔的执行过程。

第三步: 发现是原主库假故障导致的脑裂

我们是采用哨兵训制进行主从切换的,当主从切换发生时,一定最有超过预设数量(quorum配置项)的哨 兵实例和主席的心服都超时了,才会把主取到断为客观下线,然后,哨兵开始执行切换操作。哨兵切换完成 后、客户端会和新主席进行通信。及送请教修作。

但是,在切換过程中,既然客戶場仍然和原主席通信。这就表明,**原主席并没有真的发生故障**(例如主席进程柱解)。 我们猜测。主席进由于某些原因无法处理激求,也没有构成的原有的心跳,为他明氏相议地判断为 客观下线的。结果,在被判断下线之后,原主席又重新开始处理请求了,而此时,为经还没有完成主从切 换、家户编例的可以规则主张通信、客户编发的写理作数会介度主张生生为发现者。

为了验证原主库只是"假故障",我们也查看了原主库所在服务器的资源使用监控记录。

的論,我们看到原主库所在的机器有一段时间的CPU利用。它有特别病,这是我们在机器上部署的一个数据 来最似序表的,因为这个程序基本的机器的CPU等期离了,导致Redis主席无法相应心路了,在这个期间 内,明兵就把主库判断为客观下线,开始主从切换了。不过,这个数据来最程序很快恢复正常,CPU的使用 来也降下来了。此时,她主挥又开始正常被多数张了。

正因为原主库并没有真的发生<mark>故风。我们在客户端操作日志中就看到了和原主库的通信记录。等到从库被升</mark> 级为新主库后,主从集群里就有两个主库了,到这里,我们就把脑裂发生的原因摸清楚了。

为了帮助你加深建筑。我直至一张图、展示一下暗裂的发生过程。



弄清楚了脑唇发生的原因后,我们又结合主从切换的原理过程进行了分析,很快就找到数据丢失的原因了。

主从切換店,从库一旦升极为新主席,哺兵就会让原主库执行slave of命令,和新主席重新进行全量同步。 而在全量同步执行的最后阶段,原主席需要请空本地的数据,加载新主席发送的RDB文件,这样一呆,原主 库在主从均缐期间保存的新写数据数丢长了。

下面这张图直观她展示了原丰库数据男失的过程。



到这里,我们就完全弄明白了这个问题的发生过程和原因。

在主从切除的过程中,如果聚主席只是"假被房",它会触发明兵自动主从切除,一回等它从假被房中恢复 后,又开始处理请求,这样一来,就会和新主席同时存在,形成脑裂。等到哨兵让原主库和新主席做全量同 步后,原主库在切除期间保存的数据就丢失了。

看到这里,你肯定会很关心,我们该怎么应对脑裂造成的数据丢失问题呢?

如何应对脑裂问题?

刚刚说了,主从集群中的数据丢失事件,归根结底是因为发生了脑裂。所以,我们必须要找到应对脑裂问题 的策略。

既然问题是出在原主库发生假故障后仍然能接收请求上,我们就开始在主从集群机制的配置项中查找是否有 限制主库接收请求的设置。

通过查找,我们发现,Redis已经提供了两个配置项来限制主库的请求处理,分别是min-slaves-to-write和 min-slaves-max-lag-

min-slaves-to-write: 这个配置项设置了主库能进行数据同步的最少从库数量;

 min-slaves-max-lag:这个配置项设置了主从库间进行数据复制时,从库给主库发送ACK消息的最大延迟 (以秒为单位)。

有了这两个配置项后,我们就可以轻松地应对脑裂问题了。具体咋做呢?

我们可以把min-slaves-to-write和min-slaves-max-lagis兩个配置項搭配起來使用,分別給它们设置一定的 關值,假设为N和T。这两个配置项组合后的要求是,主席连接的从库中至少有N个从底,和主库进行数据复 制时的ACX增息延迟不振超过1种。否则,主要处不会再接收客户临的请求了。

即使原主库是假故障。它在假故障期间也无法响应调兵心跳,也不能和从库进行同步,自然也就无法和从库 进行几代确认了。这样一来,min-slaves-to-write相min-slaves-mo-labella是要求就无法得到满足,原主 库故会被规则被要产编读来。另户编也和不能在是其他中写。例故我了。

等到新主席上线时,就只有新主席能接收和处理客户端请求、此时,新写的数据会被直接写到新主库中。而 原主库会被哨兵降为从库,即使它的数据被清空了。也不会有新数据丢失。

我再事给你举个例子。

假设度门将min-slaves-to-inche 证据14. Penin-slaves-max-lagid图为113。 PBN 具内的own-after millisecond设度为16.6 主意的为意思则对土住了15.6 有效等只即断主席表现下线,开始进行主从切除。 则则,因为是上来上性了5分。没有一个从库柜和建工库工证为进行费度复制,是土地已无进接收客户崩 请求了。这样一块。主从则是现在,也只有新主库能接收请求,不会发生能够。也就不会发生数据丢失的 间面下。

小结

这节课,我们学习了主从切换时可能遇到的脑裂问题。脑裂是指在主从集群中,同时有两个主席都能接收写 请求。在Redis的主从切换过程中,如果发生了脑裂,客户端数据就会写入到原主席,如果原主库被降为从 库,这些部写入的数据就丢失了。

脑裂发生的原因主要是原主库发生了假故障,我们来总结下假故障的两个原因。

- 和主库部署在同一台服务器上的其他程序临时占用了大量资源(例如CPU资源),导致主库资源使用受限,短时间内无法响应心跳。其它程序不再使用资源时,主库又恢复正常。
- 主库自身遇到了阻塞的情况,例如,处理bigkey或是发生内存swap(你可以复习下<mark>第19讲</mark>中总结的导致 实例阻塞的原因),短时间内无法响应心跳,等主库阻塞解除后,又恢复正常的请求处理了。

为了应对脑裂,你可以在主从集群部署时,通过合理地配置参数min-slaves-to-write和min-slaves-maxlag,来预防脑裂的发生。

在实际应用中,可能会因为网络暂时拥塞导致从库暂时和主库的ACK消息超时。在这种情况下,并不是主库 假故障,我们也不用禁止主库接收请求。

所以,我给你的建议是。假设从库有K个,可以将min-slaves-to-write设置为K/2-1 (知果K等于1, 就设为 1) ,将min-slaves-max-lag设置为十一份(例如10~20s),在这个配置下,如果有一半以上的从库和主 库进行的ACK别能设施设计工机步,我们就禁止主席接收客户唯写请求。 这样一来,我们可以避免脑裂带来数据丢失的情况,而且,也不会因为只有少数几个从库因为网络阻塞连不 上主席,就禁止主席接收请求,增加了系统的鲁棒性。

每课一问

按照惯例,我给你提个(小问题,假设我(J·特·min-slaves-to-write设置为),min-slaves-max-lag设置为15s, 明系的down-after-milliseconds设置为10s,明兵主从切货需要5s。主席因为某些假因卡住了12s,此时, 还会发生临影词字:其从即除完成后,数据会丢失吗?

欢迎在留言区写下你的思考和答案,我们一起交流讨论。如果你觉得今天的内容对你有所帮助,也欢迎你分 享给你的朋友聪問惠。我们下节谭印。

精选留言:

Kaito 2020-11-04-00-42-2

假设我们将 min-slaves-to-write 设置为 1, min slaves-max-lag 设置为 15s, 哨兵的 down-after-millise conds 设置为 10s, 哨兵主从功操需要 5s, 主库因为某些原因卡住了 12s, 此时,还会发生脑裂吗? 主从 切除束成后,数据会 克华马克

主事十位12。这到了两点电影的的电荷。所以用点会数定上从口匙。如斯瓦印刷的时间是5、也就是 证明真正来识别完成,一种比,从国家状态中吸收国家。而且也没有数定 min-slaves-man-log间值,所 以工程在明月印度,所以在,他自己以报收客户端的资格,如果这些写除们还用即导加人用,或 就把从规则补充。

由此也可以看出,即使 Redis 配置了 min-slaves-to-write 和 min-slaves-max-lag,当脑裂发生时,还是 无法产格保证数据不丢集,它只能是尽量减少数据的丢集。

其实在这种情况下,新主席之所以会发生数据丢失,是因为旧主席从阻塞中恢复过来后,收到的写请求还 没同步到从库,从库检波喇兵提升为主席了。如果喇兵在提升从库为新主席前,主席及时很数据同步到从 痛了,那么从库提升为主席后,也不会发生数据丢失。但这种临界点的情况还是有发生的可能性,因为 R edis 本备不保证 主从即的哈姆一致。

还有一种发生脑裂的情况,就是网络分区:主挥和客户端、哨兵和从库被分割成了2个网络,主挥和客户端处在一个网络中,从焊和哨耗在另一个网络中,此时调其他会发起主从切换,组现2个全煤的情况,而 图客户端依旧可以向旧主库写入数据。等网络恢复后,主库降级为从库,新主库丢失了这期间亏损作的数据。

脑裂产生问题的本质原因是,Redis主从集群内部没有通过共识算法,来维护多个节点数据的强一败性。 它不像 Zookeeper 那样,每次写请求必须大多数节点写成功后才认为成功。当脑裂发生时,Zookeeper 主节点被阻立,此时无法写入大多数节点,写词来会直接返回失败,因此它可以保证集群数据的一致性。

另外关于 min-slaves-to-write,有一点也需要注意:如果只有 1 个从库,当把 min-slaves-to-write 设置 为 1 时,在运邮时需要小心—些。当日常对从库饭维护时,例如更换从库的产例,需要无常饭邮的从库, 再移除旧的从库才可以,或者使用 config set 统改 min-slaves-to-write 为 0 再做操作,否则会导致主库 拒绝第一影响到坐条。 30 赞

test 2020-11-04 08:50:25

课后问题:仍然可能会发生数据丢失。究其原因是redis内部没有共识算法保证数据同步,写数据的时候 D是写》主序即可连回成功。 种级同步到其序是通过导生的理的。 (4季) snailshen 2020-11-04 11:27:28

老师您好,防止脑裂我认为有2点需要注意:

1可以考虑把多个sentinel节点部署到不同的机房,减少由于网络原因导致的误判。

2.redis master主节点主机、避免高负载、部署时留有一些冗余

关于min-slaves-to-write, min-slaves-max-lag这两个配置,主要是解决主从同步数据一数性问题的,尽量减少主从用步的数据不一股,我摆得不提从根本上通过应两个参数情法额限。这项内参数失效,如果这个时候分全emtine们近点的现在分词将是为课并且这些节点到slave网络良好,那么一年金数发主从切得,造成陷阱、我是这样理解的。走起来停阱走![2]

唐朝首都 2020-11-06 08:42:43
Radis于注意会報告的契約产品

Redis无法完全避免脑裂的产生,因为其不保证主从的强一致,所以必然有产生脑裂的可能性。

Geek_dleece 2020-11-05 18:07:38

老师用的画图工具叫什么?

Trouble to the same

PPT®~

. 叶子。2020-11-05 13:214

叶子。2020-11-05 13:23:22
老师可否讲讲 Cluster模式下的嫡裂?

与君共勉 2020-11-04 7:44:49
min-slaves-max-lag是不是一般要设置成比down-after-milliseconds小的值最好?

三木子2020-11-0410:31:00
最欣赏的是排查分析问题的过程。