38-通信开销: 限制RedisCluster规模的关键因素

你好,我是慈德的。

Redis Cluster能保存的数据量以及支撑的吞吐量,跟集群的实例规模密切相关。Redis官方给出了Redis Cluster的规模上限,就是一个集群运行1000个实例。

那么,你可能会问,为什么要限定集群规模呢?其实,这里的一个关键因素就是,**实例间的通信开销会随着** 实例规模型加而增大,在果超过一定规模时(比如800节点),集群吞吐量长而会下降。所以,集群的实 压缩程令令可限制。

今天这节课,我们就来聊聊,集群实例间的通信开销是如何影响Redis Cluster规模的,以及如何降低实例间 的通信开辟。掌握了今天的内容,你就可以通过合理的配置来产来Redis Cluster的规模,同时保持高品吐 量。

实例通信方法和对集群规模的影响

Redis Cluster在运行时,每个实例上都会保存Slot和实例的对应关系(也就是Slot映射表),以及自身的状态信息。

为了让集群中的每个卖货都知道其它所有卖例的状态信息,卖例之间会按照一定的规则进行通信。这个规则 数是Gossio协议。

Gossip协议的工作原理可以概括成两点。

一是,每个实例之间会按照一定的频率,从概整中随机联选一些实例,把PINC消息发送给排选出来的实 例,用来检测这些实例是否在线,并交换被应的状态信息。PING消息中封装了发送消息的实例自身的状态 信息、部分其它实例的状态信息,以及SIot映射表。

二是,一个实例在接收到PING消息后,会给发送PING消息的实例,发送一个PONG消息。PONG消息包含 的内容和PING消息一样。

下图显示了两个实例间进行PING、PONG消息传递的情况。

 PING消息:
 实例状态信息 + 部分其它实例 状态信息 + Slot分配信息

 实例1
 实例2

 PONG消息:
 实例2状态信息 + 部分其它实例 状态信息 + Slot分配信息

Gossin协议可以保证在一段时间后、集群中的每一个实例都能获得其它所有实例的状态信息。

这样一来,即使有新节点加入、节点故障、Slot变更等事件发生,实例间也可以通过PING、PONG消息的传 递,完成集群状态在每个实例上的同步。

经过刚刚的分析,我们可以很直观地看到,实例间使用Gossip协议进行通信时,通信开销受到**通信消息大小** 和**通信频率**这两方面的影响,

消息越大、频率越高,相应的通信开销也就越大。如果想要实现高效的通信,可以从这两方面入手去调优。 接下来,我们就来具体分析下这两方面的实际情况。

首先、我们来看实例逼信的消息大小。

Gossip消息大小

Redis实例发送的PING消息的消息体是由clusterMsgDataGossip结构体组成的,这个结构体的定义如下所示:



其中,CLUSTER_NAMELEN和NET_IP_STR_LEN的值分别是心限46,分别表示,nodename和Ip这两个字 节数组的长度是40字节和46字节,我们再把结构体中其它信息的大小加起来,就可以得到一个Gossip消息 的大小了。即104字节。

每个实例在发送一个Gossip消息时,除了会传递自身的状态信息,默认还会传递集群十分之一实例的状态信息。

所以,对于一个包含了1000个实例的集群来说,每个实例发送一个PING消息时,会包含100个实例的状态 信息,总的数据量是10400字节。再加上发送实例自身的信息,一个Gossio消息大约是10KB。

此外,为了让Slott幹較表能够在不同实例同传播,PING消息中还带有一个长度为16,384 bit 的 Bitmap,这 个Bitmap的每一位对应了一个Slot、如果某一位为1,就表示这个Slot属于当前实例。这个Bitmap大小境算 成字节后,是2KB, 我们把实例状态信息和Slot分配信息相加,就可以得到一个PING消息的大小了,大约是 178R。

PONG消息和PING消息的内容一样,所以,它的大小大约是12KB。每个实例发送了PING消息后,还会收到返回的PONG消息,两个消息加起来有24KB。

虽然从绝对值上来看,24KB并不算很大,但是,如果实例正常处理的单个请求只有几KB的话,那么,实例

例发送PING/PONG消息。随着集群规模增加,这些心跳消息的数量也会越多,会占据一部分集群的网络通信带宽,进而会降低集群服务正常客户继请求的吞吐量。

除了心親消息大小会影响到通信开销,如果实例间通信非常频繁,也会导致集群网络带宽被频繁占用。那 么、Redis Cluster中宝例的通信领围是什么样的呢?

定例间通信箱室

Redis Cluster的实例启动后,默认会每秒从本地的实例列表中随机选出5个实例,再从这5个实例中找出一个 最久没有通信的实例,把PING消息发送给该实例。这是实例周期性发送PING消息的基本做法。

但是,这里有一个问题;实例选出来的这个最久没有通信的实例,毕竟是从随机选出的5个实例中挑选的, 这并不能保证这个实例就一定是整个集群中最久没有通信的实例。

所以,这有可能会出现,有些实例一直没有被发送PING消息,导致它们维护的集群状态已经过期了。

为了避免这种情况,Redis Cluster的实现在拒绝 100ms一次的频率,扫描本地的实例列表,如果发现有实 例最近一次接收 PDNG消息的时间,但是从于配置项 cluster-node-timeoutilp—单了(cluster-nodetimeoutil),被企业转给该或例准按 NNG 用用,更新企为实用上的重新状态的是

当集群规模扩大之后,因为其得需高或是不同服务器间的流量竞争。会导致实例间的网络通信延迟增加。如 集有超分实例无理。包裹技术更有发送的PONG消息,就会引起实例之间频繁地发送PING消息,这又会对集群 网络通信带某些的分钟和了。

我们来总结下单定侧部科会发送的PING适息数量、如下所示:

PING消息发送数量=1+10*实例数(最近一次接收PONG消息的时间超出cluster-nodetimeout/2)

其中,1是指单实例常规按照每1秒发送一个PING消息,10是指每1秒内实例会执行10次检查,每次检查后 会给PONG消息超时的实例发送消息。

我来借助一个例子,带你分析一下在这种通信频率下,PING消息占用集群带宽的情况。

假设单个实例检测发现。每100毫秒有10个实例的PONG消息接收裁时,那么、这个实例每秒就会发送101 个PING消息,约占1.2MB/s带宽。如果集群中有30个实例按照这种频率发送消息,就会占用36MB/s带宽, 这就会指占集群中用于服务正常端束的带宽。

所以,我们要想办法降低实例间的通信开销,那该怎么做呢?

如何降低实例间的通信开销?

为了降低实例间的通信开销,从原理上说,我们可以减小实例传输的消息大小(PING/PONG消息、Slot分 配信息),但是,因为集群实例依赖PING、PONG消息和Slot分配信息,来值持集群状态的统一,一旦减小 行物部消息大小,就会导致实所间的通信信息点少,不利于集群维护,所以,我们不能用的读中方式。

THE A STANFORD HEAD OF SHIP WITH A SAME THE PARTY OF A SAME THE PARTY OF THE PARTY

经过刚才的学习,我们现在知道,实例间发送消息的频率有两个。

- 每个实例每1秒发送一条PING消息。这个频率不算高,如果再降低该频率的话,集群中各实例的状态可能 就没办法及BIM使据了。
- 每个实例每100毫秒会做一次检测,给PONG消息接收超过cluster-node-timeout/2的节点发送PING消息。实例按照每100毫秒进行检测的频率,是Redis实例默认的周期性检查任务的统一频率,我们一般不需要修改之。

那么,就只有cluster-node-timeout这个配置项可以修改了。

配置項cluster-node-timeout定义了集群实的被判断为故障的心理把部封词,就认是15秒。如果clusternode-timeout值比较小,那么,在大规模集群中,就会比较对影响出现PONG消息接收起时的情况,从而 导致实何格与季执行功。"给PONG消息起时的实例发生的NSS编章 这个抽样。

所以,为了避免过多的心跳消息挤占集群模器;我们可以调大cluster-node-timeout值,比如说调大到20秒 或25秒。这样一来,PONG消息指收超时的明点就会有所超解,单实例也不用频繁地每秒执行10次心就发 详操作了。

当然,我们也不要把clusion node funeout调得太大,否则,如果实例真的发生了故障。我们就需要等待 cluster-node-timeoutleyfer。才能检测出这个故障,这又会导致实际的故障恢复时间被延长,会影响到集 数据命的不使得解

为了验证调整cluster-node-timeout值后,是否能减少心紊消息占用的集群网络带宽,我给你提个小建议: 你可以在调整cluster-node-timeout值的前后,使用tcpdump命令抓取实例发送心磷信息网络包的情况。

例如,执行下面的命令后,我们可以抓取到192.168.10.3机器上的实例从16379端口发送的心跳网络包,并 把网络包的内容保存到几点qq文件中:

```
topdump host 192.168.10.3 port 16379 -1 原辛器 -w /tmp/r1.cop
```

通过分析网络包的数量和大小,就可以判断调整cluster-node-timeout值前后,心跳消息占用的帶宽情况 マ

小结

这节端,契約你介紹了Redis Clustor英侗阁以Gossip协议进行通信的机制。Redis Clustor进行时,各实例间 需要通过PING、PONG消息进行信息交换,这些心族消息包含了当前实例和部分其它实例的状态信息,以及 Slott/备价很高。这种操作机器有勤于Redis Clustor中的所有坚彻解期有宗教的编辑状态很高。

跳消息,影响集群服务正常请求。

最后,我也给你一个小建议,虽然我们可以通过调整cluster-node-timeout配置填减少心跳消息的占用带宽情况,但是,在实际应用中,如果不是特别需要大容量素群,我建议你把Redis Cluster 的规模控制在 400-500个字段。

假设单个实例每秒能支撑8万请求操作 (8万QPS) ,每个主实例配置1个从实例,那么、400-500个实例可 支持 1600万-2000万(PS (200/250个主实例*8万QPS=1600/2000万(PS) ,这个各社量性能可以满足不少 中条件部的需要。

毎课一问

按照價例,我給你提个小问题,如果我们采用跟Codis保存Slotte配值总和完成的方法,把集群实例状态信息和Stotte配信息保存在第三方的存储系统上(例如Zookspe)。这种方法会对集群规模产生什么影响 822

欢迎在留言区写下你的思考和答案,我们一起受赔讨论。如果你觉得今天的内容对你有所帮助,也欢迎你分 享给你的朋友或周事。我们下节读见。

精选留言:

- Mailo 2020-11.20[bn-05kg)
如果采用类似 Lodis R 萨 Slot 信息的方法,把集群实例状态信息和 Slot 分配信息保存在第三方的存储系统上(例如20%ceper),这种方法会对集群规模产生什么影响?

由于Redic Cluster 值个资明需要存弃解弃案的指抗危息,所以电验加一个资料。据需要多一次其地 实例的通信开销,如果有 N个实例,集群就要存储 N份完整的路由信息。则如果像 Codis SaF F, 把Stott 信息存储在第三方存储上,但无无定果存所得与少,这些现在在第三方存储上完存存储一位。也就提 。最有内容值许用,不会随着实例的增加而增长。当集和需要用到这些信息时,直接从第三方存储上获 整即可。

Redis Cluster 把所有功能都集成在了 Redis 实例上,包括路由表的交換、实例健康检查、故障自动切换 等等,这么做的好处是。部署和使用非兩周率,只需要那署实例,然后让多个实例组成切片集群即可提供 服务。但缺点也很明显,每个实例负责的工作比较重,如果看源码实现,也不太容易理解,而且如果其中 一个少能出现见证。只能升极整个 Redis Server 亲戚法。

而 Codis 把这些功能拆分成多个组件,每个组件负责的工作都非常纯粹,codis-proxy 负责转发请求,co dis-dashboard 负责路租表的分发、数据还移近朝,codis-server 负责数据存储和股据还移,明兵负责故 简自动动境,codis-fe 负责提供友好的运输界器,每个但作都可以单独升级,这些组件相互配合,完成整 个集解的对外服务。但就转点是但件比较多,影影和维护比较复杂。

在实际的业务场景下,我觉得应该尽量避免非常大的分片集群,太大的分片集群一方面存在通信开销大的 问题,另一万亩也会智效集群取得越来越难以维护。而且当集群协问题时,对业务的影响也比较集中。 建 设计对不同的业务线、业务模块,单趋部署不同的分片集群,这样方便运维和管理的同时,出现问题也只 会参加某一个少条模块。[7替]

Aniou 2020-11-20 10:04

请教老师一个问题: Redis 哨兵模式中,默认情况下从实例是否接受读请求? 哨兵模式中从实例的规模有 没有限制?假设单个实例每秒能支撑8万 QPS,使用"一主二从三哨兵"方式部署,"一主二从"能支

- 东 2020-11-20 08:55:58
 - "PING 消息中封装了发送消息的实例自身的状态信息、部分其它实例的状态信息,以及 Slot 映射表。" 如果两个实例中包含的 "其他实例的状态信息" 不一致,实例2如何处理呢? 是比较时间戳吗?